Unidad 2 — Tarea 4: Reporte de fusión y agrupación

Asignatura: Programación Avanzada para Ciencia de Datos
Tema: Integración de datos mediante Pandas

1. Objetivo

Integrar información de ventas, productos y sucursales mediante operaciones `merge`, verificar la integridad de los registros y analizar los ingresos por sucursal, categoría y mes mediante `groupby` y `pivot_table`.

2. Estructura y relaciones de las tablas

Se utilizaron tres fuentes de datos:

Tabla	Registros originale	Clave
Ventas	612	`venta_id`
Productos	12	`producto_id`
Sucursales	4	`sucursal_id`

Diagrama de relaciones:

PRODUCTOS VENTAS SUCURSALES
producto_id (PK) ——— producto_id (FK)
sucursal_id (FK) ——— sucursal_id (PK)

Cada venta se relaciona con un producto y una sucursal mediante sus identificadores. Las relaciones son de muchos a uno (`many_to_one`), ya que un mismo producto o sucursal puede aparecer en múltiples ventas.

3. Limpieza y fusión de datos

Inicialmente se identificaron 12 registros completamente duplicados, 26 valores faltantes en `cantidad` y 18 en `precio_unitario`. También se encontraron inconsistencias de espacios y mayúsculas en los identificadores de sucursal.

Se eliminaron los duplicados exactos, se normalizaron las claves y se convirtieron las fechas a un tipo adecuado. Los valores faltantes se conservaron para evitar inventar importes.

Posteriormente se realizaron dos fusiones `left` utilizando `validate="many_to_one"`: primero ventas con productos y después con sucursales.

Comprobación de integridad: después de eliminar los duplicados quedaron 600 ventas. Ambas fusiones conservaron las 600 filas y todas encontraron correspondencia en sus respectivos catálogos.

4. Resultados de las agrupaciones

Tabla 1. Ingresos por sucursal

Sucursal	Ingreso registrado
Tláhuac Centro	$75,776.50
La Turba	$67,364.29
Bosque de Tláhuac	$31,135.65
Lago Tláhuac	$26,750.23

Unidad 2 — Tarea 4: Reporte de fusión y agrupación

Asignatura: Programación Avanzada para Ciencia de Datos
Tema: Integración de datos mediante Pandas

Tabla 2. Ingresos por categoría

Categoría	Ventas	Ingreso registrado
Básicos	198	$88,010.74
Abarrotes	143	$56,321.85
Bebidas	103	$22,909.84
Lácteos	56	$19,633.01
Limpieza	100	$14,151.23

Tabla 3. Ingresos mensuales por sucursal (MXN)

Mes 2026	Bosque	La Turba	Lago	Centro
Enero	5,396	4,099	3,755	4,773
Febrero	2,169	6,066	2,119	19,817
Marzo	11,040	5,819	2,288	6,872
Abril	5,546	7,412	3,582	5,210
Mayo	3,667	38,272	1,299	31,380
Junio	3,318	5,694	13,708	7,725

Los importes mensuales se redondearon a pesos enteros para facilitar su presentación. Las cifras completas permanecen en el notebook.

5. Conclusiones

Tláhuac Centro fue la sucursal con mayores ingresos registrados, con $75,776.50 y un ticket promedio calculable de $384.65
Básicos fue la categoría que más ingresos generó, con $88,010.74 correspondientes a 198 ventas registradas.
Mayo de 2026 fue el mes con mayores ingresos registrados, con $74,618.13, mientras que enero presentó el menor ingreso, con $18,023.89.

6. Justificación del tipo de fusión

Se utilizó `LEFT JOIN` para conservar todas las ventas durante su integración con los catálogos, incluso si alguna clave no encontraba correspondencia. Un `INNER JOIN` habría eliminado las ventas sin coincidencia, mientras que un `OUTER JOIN` también habría incorporado productos o sucursales sin ventas, generando filas adicionales.
La opción `validate="many_to_one"` permitió comprobar que las claves de los catálogos fueran únicas y evitar duplicaciones accidentales durante las fusiones.
Limitación: 43 ventas no permitieron calcular su importe debido a datos faltantes. Por tanto, los ingresos presentados corresponden a los registros con información suficiente y no necesariamente representan el total real.